MEMORIA TECNICA
PROYECTO EDA

Optimización de Refugios y Análisis Predictivo de Estancia en el Austin Animal Center

JAVIER LASTRA VAZQUEZ

NOVIEMBRE · 2026

1. Introducción y Planteamiento del Problema

1.1 Justificación del Caso de Uso

La gestión operativa de los refugios de animales municipales se enfrenta crónicamente a un dilema de capacidad física y recursos financieros limitados. El objetivo principal de este proyecto es analizar de forma cuantitativa el flujo histórico de entradas y salidas de animales en el **Austin Animal Center** (Texas, EE. UU.) —el mayor refugio de admisión abierta bajo directrices *No-Kill*— para identificar qué factores incrementan el tiempo de permanencia en jaula (*Days_in_Shelter*) y cómo transformar estos hallazgos en herramientas de optimización operativa.

1.2 Formulación de Hipótesis Iniciales

Antes de iniciar el Análisis Exploratorio de Datos (EDA), se plantearon cuatro hipótesis cuantitativas para validar o refutar creencias comunes del sector:

1. **El "Síndrome del Perro Negro":** Los perros de pelaje oscuro experimentan un tiempo de estancia significativamente mayor debido a sesgos estéticos de adopción.
2. **Estacionalidad del Colapso:** El pico crítico de saturación del refugio se concentra en los meses de primavera/verano (mayo-julio) debido al nacimiento masivo de camadas (*kitten/puppy season*).
3. **Paradoja Sanitaria al Ingreso:** Los animales que ingresan en estado de salud vulnerable (*Injured*, *Sick*) presentan una alta probabilidad de eutanasia, frente a la hipótesis de una red de derivación activa (*Transfer*).
4. **Comparativa por Especie:** Los perros sufren estancias medianas superiores en jaula en comparación con los gatos.

2. Fuentes de Datos y Diccionario de Variables

2.1 Origen de los Datos

Se han utilizado dos fuentes públicas oficiales del portal de datos abiertos del *Austin Animal Center* (alojadas en la carpeta src/data/ del repositorio):

- **Austin Animal Center Intakes.csv:** Registro histórico de todas las admisiones de animales en el centro.
- **Austin Animal Center Outcomes.csv:** Registro histórico de todas las resoluciones de salida del centro.

2.2 Diccionario de Variables Principales

- **Animal ID**: Identificador único alfanumérico asignado a cada animal.

- **DateTime**: Marca temporal exacta de la entrada o salida del refugio.
- **Intake Type**: Motivo de ingreso (*Stray* [callejero], *Owner Surrender* [entrega de dueño], *Wildlife*, etc.).
- **Intake Condition**: Estado físico o sanitario al entrar (*Normal*, *Injured*, *Sick*, *Nursing*, etc.).
- **Animal Type**: Especie del animal (*Dog*, *Cat*, *Bird*, etc.).
- **Breed & Color**: Raza y descripción cromática del pelaje.
- **Outcome Type**: Resolución final de salida (*Adoption*, *Transfer*, *Return to Owner*, *Euthanasia*, etc.).

3. Metodología y Tratamiento de Datos

3.1 Limpieza y Preprocesamiento en Pandas

El flujo de procesamiento implementado en el módulo auxiliar src/utils/data_cleaning.py constó de las siguientes fases técnicas:

1. **Parseo de Fechas:** Conversión de las columnas DateTime a formato nativo datetime de Pandas, gestionando errores de conversión mediante errors='coerce'.
2. **Cruce Inteligente de Tablas (Merge Asof):** Para evitar la duplicación de registros históricos de animales que ingresaron múltiples veces, se ordenaron cronológicamente ambos datasets y se utilizó la función pd.merge_asof agrupando por Animal ID para emparejar cada entrada con su salida posterior más cercana en el tiempo.
3. **Creación de la Métrica Clave (Days_in_Shelter):** Derivada de la diferencia temporal entre la fecha de salida (OutcomeDate) y la fecha de entrada (IntakeDate), convertida a días decimales mediante la división de los segundos transcurridos por 86.400.
4. **Tratamiento de Valores Nulos:** Eliminación estricta de registros huérfanos sin fecha de salida asociada para garantizar la consistencia en el cálculo de estancias.
5. **Variables Derivadas y Categóricas:** Extracción de metadatos temporales (Intake_Month, Intake_Year) y creación de una máscara booleana (Is_Black) para aislar los animales con descripciones de pelaje oscuro mediante métodos de cadenas de texto (str.contains).

4. Análisis Exploratorio de Datos (EDA) y Validación de Hipótesis

Tras consolidar una muestra limpia de **156.041 registros**, se obtuvieron los siguientes estadísticos descriptivos globales:

- **Mediana global de estancia:** 5,84 días (el 50% de los animales abandonan el refugio en menos de una semana).
- **Media global de estancia:** 20,16 días (valor fuertemente sesgado hacia arriba por *outliers* de larga estancia que superan los 1.000 días).
- **Distribución de salidas:** Adopción (*Adoption*): 47,32%; Traslado (*Transfer*): 28,53%; Retorno a propietario (*Return to Owner*): 15,63%; Eutanasia: 6,33%.

4.1 Verificación de las Hipótesis

- **H1 (Síndrome del Perro Negro):** Se **cumple parcialmente**. La mediana de estancia en perros negros es de 5,90 días frente a los 5,52 días de otros pelajes. Aunque la brecha unitaria es pequeña (+0,38 días / ~9 horas), acumulada en la población total representa más de 11.800 días adicionales de jaula.
- **H2 (Estacionalidad):** Se **cumple**. Los ingresos se disparan masivamente en mayo (16.044), junio (15.634) y julio (14.343), demostrando que la saturación responde al ciclo de reproducción (*kitten season*) y no al abandono estival de agosto.
- **H3 (Paradoja Sanitaria):** Se **refuta la eutanasia masiva**. Los animales que ingresan enfermos o heridos (*Injured*, *Sick*) son derivados mayoritariamente a través de la red de traslados (*Transfer* >40-60%), validando el rol del refugio como centro de triaje operativo.
- **H4 (Perros vs. Gatos):** Se **refuta respecto a la creencia inicial**. Los gatos presentan una mediana de estancia superior (7,12 días) a la de los perros (5,78 días) debido a los periodos de lactancia y fomento previos a la adopción oficial.

5. Dificultades Técnicas Encontradas y Limitaciones

1. **Ambigüedad en el control de razas cruzadas:** La categorización exhaustiva de razas mixtas (*Mix*) en los registros originales dificultó un análisis pormenorizado de restricciones por tamaño de raza estricto.
2. **Ausencia de seguimiento post-adopción:** El dataset final carece de métricas sobre la tasa de devolución a medio plazo tras la adopción directa.
3. **Coherencia temporal en reingresos:** El uso de merge_asof requirió depurar casos cruzados en animales con admisiones recurrentes muy próximas en el tiempo.

6. Conclusiones y Propuesta de Futuro

6.1 Conclusiones de Negocio

El análisis demuestra que la eficiencia de un refugio no depende de reaccionar ante picos de abandono, sino de anticiparse a ellos. Reducir la mediana global de estancia en apenas 1,5 días libera una cuarta parte de la capacidad física de las instalaciones y optimiza drásticamente el presupuesto operativo.

6.2 Puente Socioeducativo (Contexto España)

Para contextualizar el impacto social del proyecto, se contrastaron los datos de Austin con el estudio de la **Fundación Affinity**, poniendo de relieve que frente a la alta rotación estadounidense (mediana de ~6 días), las protectoras en España afrontan estancias prolongadas de 8 a 13 meses en cheniles y un 75% de ingresos sin microchip identificativo.

6.3 Visión de Futuro (Teaser de Machine Learning)

Como evolución natural del proyecto, la estructura de datos consolidada servirá como base para entrenar en el próximo módulo un **modelo de Machine Learning supervisado (Regresión y Clasificación)** capaz de predecir desde el primer día de ingreso el riesgo de estancia prolongada de un animal, automatizando la derivación a redes de acogida preventiva.